

Лабораторная работа № 4 «Корреляционный анализ»

студента Грачева Игоря группы Б23-504. Дата сдачи: _____

Ведущий преподаватель: _____ оценка: _____ подпись: _____

Вариант №5

Цель работы: изучение функций Statistics and Machine Learning Toolbox™ MATLAB / Python SciPy.stats для проведения корреляционного анализа данных.

1. Исходные данные

Характеристики наблюдаемых случайных величин:

СВ	Распределение	Параметры	Математическое ожидание, m_i	Дисперсия, σ_i^2	Объем выборки, n
X	$N(5, 2)$	$m = 5, \sigma = 2$	5	4	100
Y	$N(5, 2)$	$m = 5, \sigma = 2$	5	4	

Примечание: для генерации случайных чисел использовать функции **rand**, **randn**, **chi2rnd** (scipy.stats: **uniform.rvs**, **norm.rvs**, **chi2.rvs**)

Выборочные характеристики:

СВ	Среднее, \bar{x}_i	Оценка дисперсии, s_i^2	КК по Пирсону, \tilde{r}_{XY}	КК по Спирмену, $\hat{\rho}_{XY}$	КК по Кендаллу, $\tilde{\tau}_{XY}$
X	4.5520	3.1480	-0.0727	-0.0777	-0.0501
Y	5.1883	4.1221			


Проверка значимости коэффициентов корреляции:

Статистическая гипотеза, H_0	p -value	Статистическое решение при $\alpha = 0.05$	Ошибка стат. решения
$H_0: r_{XY} = 0$	0.4723	Не отвергаем	Нет
$H_0: \rho_{XY} = 0$	0.4424	Не отвергаем	Нет
$H_0: \tau_{XY} = 0$	0.4602	Не отвергаем	Нет

Примечание: для проверки гипотез использовать функцию `corr` (`scipy.stats.pearsonr`)

2. Визуальное представление двумерной выборки

Диаграмма рассеяния случайных величин X и Y:



Примечание: для построения диаграммы использовать функции `plot`, `scatter` (`matplotlib.pyplot.scatter`)

3. Проверка независимости методом таблиц сопряженности

Статистическая гипотеза: $H_0 : F_Y(y | X \in \Delta_1) = \dots = F_Y(y | X \in \Delta_k) = F_Y(y)$

Эмпирическая/теоретическая таблицы сопряженности:

$X \backslash Y$	[0.22; 2.25)	[2.25; 4.29)	[4.29; 6.32)	[6.32; 8.35)	[8.35; 10.39]
$\Delta_1 = [1.00; 2.78)$	$\frac{1}{0.9}$	$\frac{6}{5.76}$	$\frac{6}{6.66}$	$\frac{4}{2.88}$	$\frac{1}{1.80}$

$\Delta_2 = [2.78; 4.55)$	1 1.75	10 11.20	17 12.95	4 5.60	3 3.50
$\Delta_3 = [4.55; 6.32)$	2 1.50	11 9.60	6 11.10	6 4.80	5 3.00
$\Delta_4 = [6.32; 8.09)$	1 0.7	3 4.48	7 5.18	2 2.24	1 1.40
$\Delta_5 = [8.09; 9.86]$	0 0.15	2 0.96	1 1.11	0 0.48	0 0.30

Примечание: для группировки использовать функцию **hist3** (**matplotlib.pyplot.hist2d**)

Выборочное значение статистики критерия	p -value	Статистическое решение при $\alpha = 0.05$	Ошибка стат. решения
10.9347	0.8135	Не отвергаем	Нет

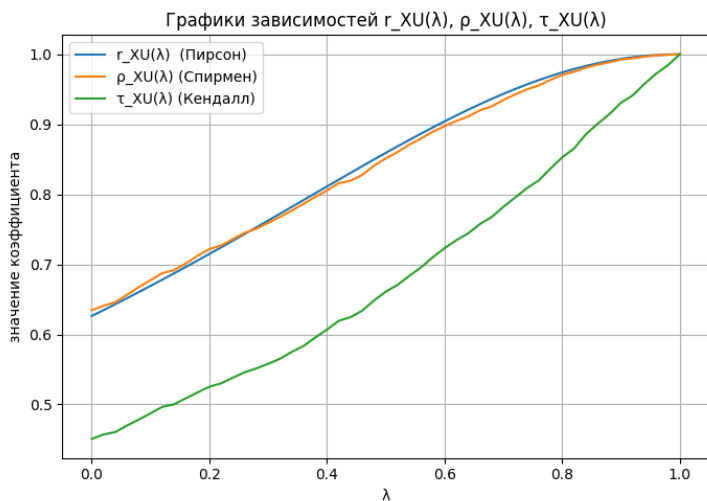
Примечание: для проверки гипотезы использовать функцию **crosstab** (**scipy.stats.chi2_contingency**)

4. Исследование корреляционной связи


Случайная величина $U = \lambda X + (1-\lambda)Y$, $\lambda \in [0; 1]$

Случайная величина $V = \lambda X^3 + (1-\lambda)Y^3$ $\lambda \in [0; 1]$

Графики зависимостей коэффициента корреляции $\tilde{r}_{XU}(\lambda)$, рангового коэффициента корреляции по Спирмену $\tilde{\rho}_{XU}(\lambda)$, по Кендаллу $\tilde{\tau}_{XU}(\lambda)$



Графики зависимостей $\tilde{r}_{XV}(\lambda)$, $\tilde{\rho}_{XV}(\lambda)$, $\tilde{\tau}_{XV}(\lambda)$



Выводы: все коэффициенты монотонно растут от $\lambda = 0$ к $\lambda = 1$. Коэффициенты Спирмена и Кендалла почти везде чуть выше Пирсона. Для пары (X, U) зависимости почти линейные и растут почти параллельно друг другу, для пары (X, V) кривизна графиков сильнее.

Диаграмма рассеяния случайных величин X и V при $\lambda = 0$:




Диаграмма рассеяния **рангов** случайных величин X и V при $\lambda = 0$:

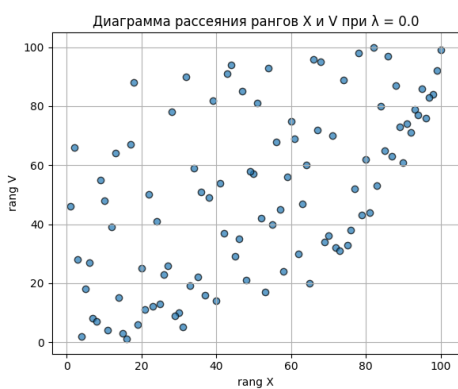


Диаграмма рассеяния случайных величин X и V при $\lambda = 1$:





Диаграмма рассеяния **рангов** случайных величин X и V при $\lambda = 1$:



Примечание: для расчёта рангов использовать функцию **tiedrank** (**scipy.stats.rankdata**)

Выводы: при $\lambda = 0$ видно, что при больших X больше и V , их связь возрастает, поэтому линейная корреляция Пирсона есть. Связь между рангами X и V монотонная, но не идеальная, значит коэффициенты Спирмена и Кендалла высокие, но меньше 1.

При $\lambda = 1$ видно, что связь между X и V строго монотонная, поэтому корреляция Пирсона близка к 1. Диаграмма рангов образует почти ровную прямую, что означает почти идеальную ранговую зависимость, то есть коэффициенты Спирмена и Кендалла близки к 1.